Łukasz Jaworski155 NCI

Labolatorium 06

Deep Learning – rozpoznawanie zwierząt z obrazków

W tym labolatorium ponownie będę korzystać z języka R oraz programu Rstudio, tym razem jednak będę wykorzystywać bazę obrazów psów i kotów aby nauczyć sieć je rozpoznawać. Skorzystałem z bazy dostępnej pod adresem: https://www.kaggle.com/c/dogs-vs-cats/data .

Podobnie jak w poprzedniej pracy rozpoczynam od dodania do projektu potrzebnych bibliotek – w tym przypadku jest to **drat**(pozwoli nam wprowadzić pliki obrazów do repozytorium programu) oraz **mxnet,** który odpowiedzialny jest za przetwarzanie obrazów, na podstawie którego sieć będzie się uczyć rozpoznawania.

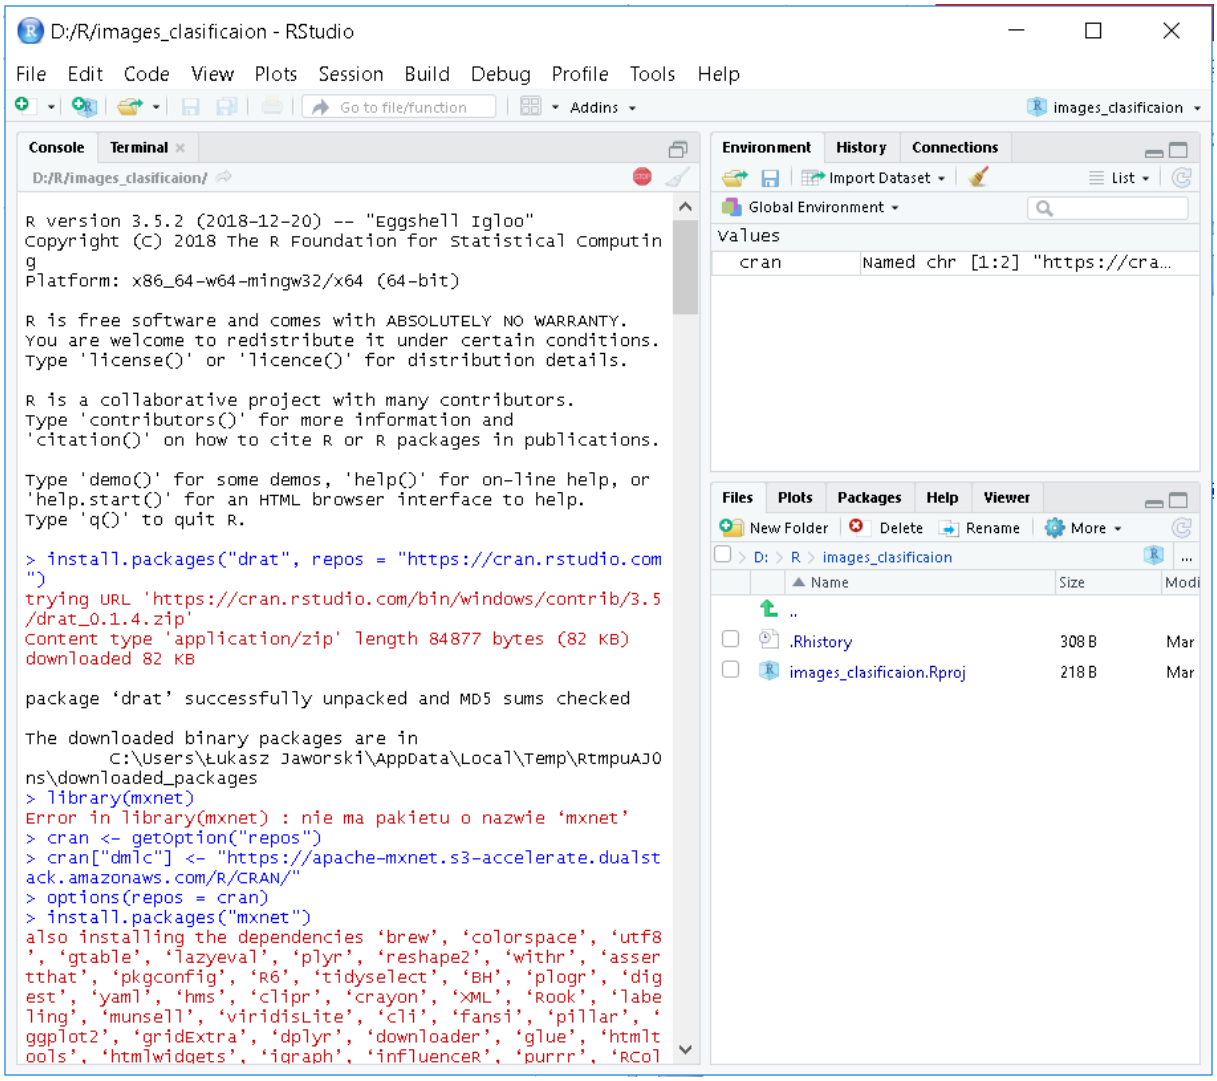

Posiadając obie biblioteki wczytujemy do programu lokalizację plików do nauki i treningu.

```
> library(mxnet)
> image_dir <- "L:\\LAB\\dogs-vs-cats\\train"
> source("https://bioconductor.org/biocLite.R")
trying URL 'https://bioconductor.org/packages/3.7/bioc/bin/w
indows/contrib/3.5/BiocInstaller_1.30.0.zip'
Content type 'application/zip' length 102191 bytes (99 KB)
downloaded 99 KB

package 'BiocInstaller' successfully unpacked and MD5 sums c
hecked

The downloaded binary packages are in
        C:\Users\Łukasz Jaworski\AppData\Local\Temp\RtmpuAJ0
ns\downloaded_packages
Bioconductor version 3.7 (BiocInstaller 1.30.0), ?biocLite
  for help
A newer version of Bioconductor is available for this
  version of R, ?BiocUpgrade for help
> biocLite("EBImage")
BioC_mirror: https://bioconductor.org
Using Bioconductor 3.7 (BiocInstaller 1.30.0), R 3.5.2
  (2018-12-20).
Installing package(s) 'EBImage'
also installing the dependencies 'bitops', 'BiocGenerics', '
abind', 'tiff', 'jpeg', 'png', 'locfit', 'fftwtools', 'RCurl
'
```

Będzie nam potrzebna jeszcze jedna biblioteka - EBImage, która wspomaga proces analizy plików graficznych. Dzięki niej możemy też załadować plik graficzny w oknie programu.

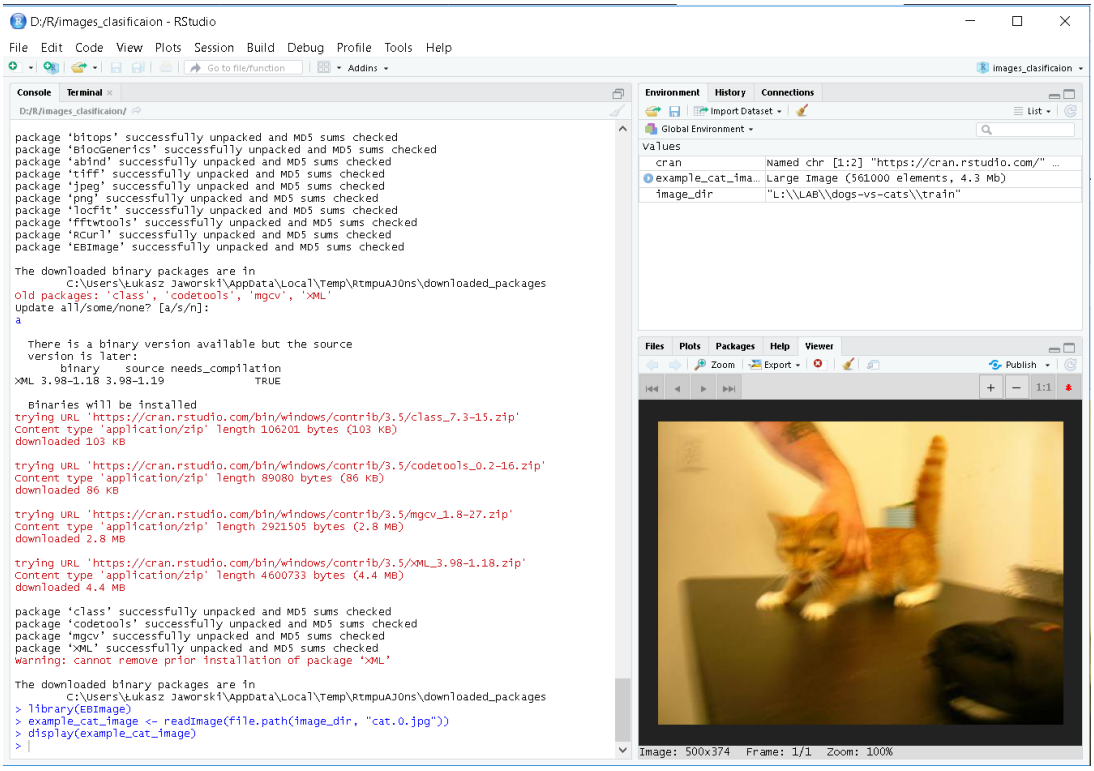

Na poniższym zrzucie widać operację utworzenia macierzy obrazów z podanej ścieżki do folderu. Folder testowy posiada podział na koty i psy, by program był w stanie określić jakie cechy będą odpowiadające dla różnych rodzajów zwierząt.

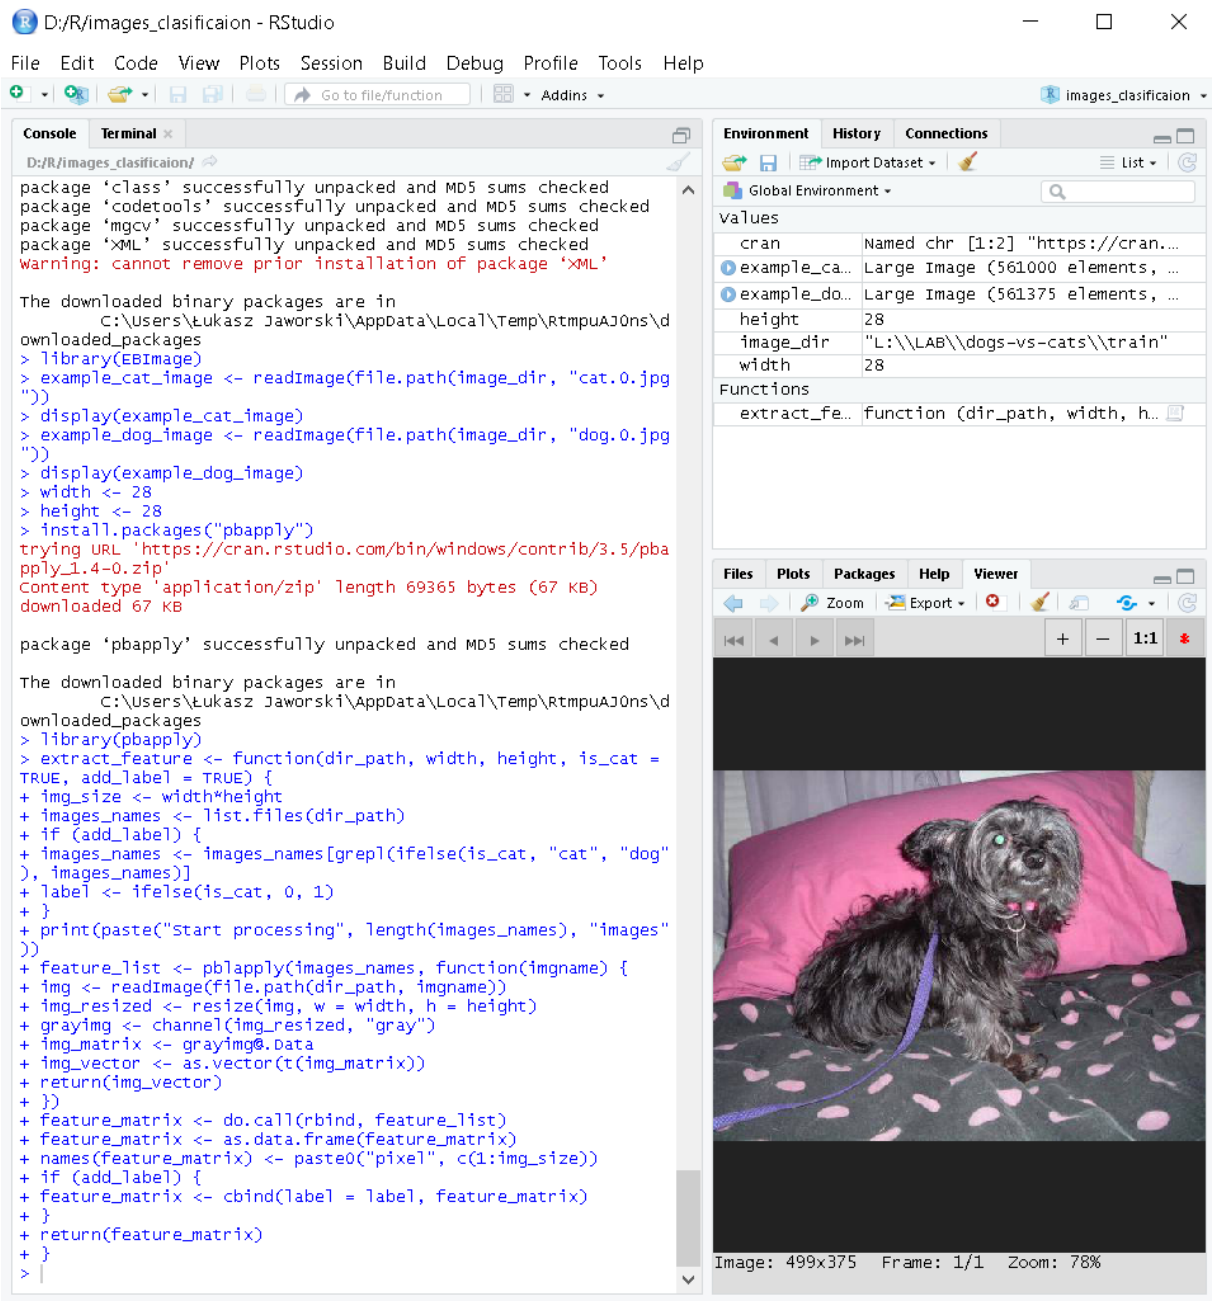

Każdy z obrazów zostaje rozbity na mapę w odcieniach szarości, by uzyskać kontury postaci, które będą przetwarzane w programie.

Uzyskane w ten sposób obrazy możemy podzielić na zbiory do trenowania i testowania sieci.

```
> library(caret)
Ładowanie wymaganego pakietu: lattice
Ładowanie wymaganego pakietu: ggplot2
> complete_set <- rbind(cats_data, dogs_data)
> training_index <- createDataPartition(complete_set$label, p =
.9, times = 1)
> training_index <- unlist(training_index)
> train_set <- complete_set[training_index,]
> dim(train_set)
[1] 22500   785
> test_set <- complete_set[-training_index,]
> dim(test_set)
[1] 2500  785
>
```


```
> library(caret)
Ładowanie wymaganego pakietu: lattice
Ładowanie wymaganego pakietu: ggplot2
> complete_set <- rbind(cats_data, dogs_data)
> training_index <- createDataPartition(complete_set$label, p =
.9, times = 1)
> training_index <- unlist(training_index)
> train_set <- complete_set[training_index,]
> dim(train_set)
[1] 22500   785
>
```


Należy też utworzyc odpowiednie obiekty, które będą dostarczane sieci. Między innymi ustawiamy właściwości macierzy treningowych oraz obrazów w nich zawartych, np. ich rozmiary.

```
> train_data <- data.matrix(train_set)
> train_x <- t(train_data[, -1])
> train_y <- train_data[,1]
> train_array <- train_x
> dim(train_array) <- c(28, 28, 1, ncol(train_x))
> test_data <- data.matrix(test_set)
> test_x <- t(test_set[,-1])
> test_y <- test_set[,1]
> test_array <- test_xtest_array <- test_x
> dim(test_array) <- c(28, 28, 1, ncol(test_x))
```

W tym momencie jesteśmy przygotowani do załadowania wszystkich zapisanych informacji przy użyciu wspomnianej wcześniej biblioteki mxnet. Następnie ustawiamy właściwości sieci neuronowej , jednak nauka rozpoznawania obrazów wymaga innej złożoności sieci niż w poprzednim laboratorium.

Obiekty **conv, tanh** i **pool** określają konwulsyjne warstwy sieci, a **fcl –** warstwy łączące. Na podstawie ilości filtrów i węzłów nakładanych na obraz określamy jak dokładnie sieć ma sprawdzać własności poszczególnych obrazów. Następnie ustalamy wygląd modelu sieci oraz uruchamiamy trenowanie.

```
> library(mxnet)
> mx_data <- mx.symbol.Variable('data')
> conv_1 <- mx.symbol.Convolution(data = mx_data, kernel = c(5,
5), num_filter = 20)
> tanh_1 <- mx.symbol.Activation(data = conv_1, act_type = "tanh
")
> pool_1 <- mx.symbol.Pooling(data = tanh_1, pool_type = "max",
kernel = c(2, 2), stride = c(2,2 ))
> conv_2 <- mx.symbol.Convolution(data = pool_1, kernel = c(5,5)
, num_filter = 50)
> tanh_2 <- mx.symbol.Activation(data = conv_2, act_type = "tanh
")
> pool_2 <- mx.symbol.Pooling(data = tanh_2, pool_type = "max",
kernel = c(2, 2), stride = c(2, 2))
> flat <- mx.symbol.Flatten(data = pool_2)
> fcl_1 <- mx.symbol.FullyConnected(data = flat, num_hidden = 50
0)
> tanh_3 <- mx.symbol.Activation(data = fcl_1, act_type = "tanh"
)
> fcl_2 <- mx.symbol.FullyConnected(data = tanh_3, num_hidden =
2)
> NN_model <- mx.symbol.SoftmaxOutput(data = fcl_2)
> mx.set.seed(100)
> device <- mx.cpu()
> model <- mx.model.FeedForward.create(NN_model, X = train_array
, y = train_y,
+ ctx = device,
+ num.round = 30,
+ array.batch.size = 100,
+ learning.rate = 0.05,
+ momentum = 0.9,
+ wd = 0.00001,
+ eval.metric = mx.metric.accuracy,
+ epoch.end.callback = mx.callback.log.train.metric(100))
Start training with 1 devices
```

```
Start training with 1 devices
[1] Train-accuracy=0.495511107842127
[2] Train-accuracy=0.495199996630351
[3] Train-accuracy=0.495199996630351
[4] Train-accuracy=0.495199996630351
[5] Train-accuracy=0.495199996630351
[6] Train-accuracy=0.495644440915849
[7] Train-accuracy=0.498933329714669
[8] Train-accuracy=0.527777774201499
[9] Train-accuracy=0.576533334387673
[10] Train-accuracy=0.615199998087353
[11] Train-accuracy=0.647422222296397
[12] Train-accuracy=0.672000001536475
[13] Train-accuracy=0.68986666838328
[14] Train-accuracy=0.707555555237664
[15] Train-accuracy=0.718977778487735
[16] Train-accuracy=0.732222223811679
[17] Train-accuracy=0.741955555809869
[18] Train-accuracy=0.758488889800178
[19] Train-accuracy=0.76848888847563
[20] Train-accuracy=0.781066664324866
[21] Train-accuracy=0.792488886515299
[22] Train-accuracy=0.805377775298225
[23] Train-accuracy=0.808844442632463
[24] Train-accuracy=0.820933333502875
[25] Train-accuracy=0.823644442293379
[26] Train-accuracy=0.82937777545717
[27] Train-accuracy=0.837822222179837
[28] Train-accuracy=0.836622220675151
[29] Train-accuracy=0.844044443236457
[30] Train-accuracy=0.857777777247959
```

Ostatecznie uzyskaliśmy prawodpodobieństwo odgadnięcia zwierzęcie na poziomie 85% w zbiorze trenującym. Należy jeszcze sprawdzić jak program sobie radzi w losowym zbiorze testowym.

```
> predict_probs <- predict(model, test_array)
> predicted_labels <- max.col(t(predict_probs)) - 1
> table(test_data[, 1], predicted_labels)
   predicted_labels
      0   1
  0 740 510
  1 329 921
> sum(diag(table(test_data[, 1], predicted_labels)))/2500
[1] 0.6644
>
```

W tym przypadku osiągnęliśmy prawdopodobieństwo na poziomie 66%. Moglibyśmy osiągnąć wyższy wynik zmieniając własności sieci lub ilości epok, jednak w przypadku przetwarzania plików graficznych każda zmiana w sieci drastycznie wpływa na czas nauki takiej sieci, nie zawsze poprawiając wyniki nauki.